

Generowanie cyfr pisanych odręcznie na bazie sieci neuronowej o architekturze autoencodera

Analiza porównawcza różnych architektur oraz wyników

Jakub Barylak, Michał Jagoda, Piotr Marcol

Politechnika Śląska

11 czerwca 2025

Plan prezentacji

- 1 Wprowadzenie
- 2 Przegląd zaimplementowanych modeli i ich architektur
- 3 Wyniki eksperymentów
- 4 Wizualizacje i przykłady
- 5 Wnioski i kierunki rozwoju

Cel prezentacji

Przedstawienie wyników i porównanie różnych modeli generatywnych na zbiorze danych MNIST.

- Analiza architektur Autoencoderów, VAE, GAN i Diffusion Model.
- Porównanie jakości generowanych próbek.

Zaimplementowane modele


Podstawowe modele

- **Autoencoder:** Klasyczny model do rekonstrukcji danych.
- **Conditional VAE:** Wariacyjny autoencoder z warstwą warunkującą, umożliwiający generowanie danych na podstawie etykiet.
- **Convolutional VAE:** Wariacyjny autoencoder z warstwami konwolucyjnymi, lepiej przystosowany do obrazów.

Zaawansowane modele

- **Vector Quantized VAE (VQ-VAE):** Model łączący VAE z dyskretną przestrzenią latentną.
- **Generative Adversarial Network (GAN):** Model oparty na rywalizujących sieciach neuronowych.
- **Diffusion Model:** Model generatywny oparty na procesie redukcji szumu.

Architektura Autoencodera



Rysunek: Schemat architektury Autoencodera

Architektura Conditional VAE



Rysunek: Schemat architektury Conditional VAE

Architektura Convolutional VAE




Rysunek: Schemat architektury VAE

Architektura GAN




Rysunek: Schemat architektury GAN

Architektura VQ-VAE



Rysunek: Schemat architektury VQ-VAE

Architektura Diffusion Model



Rysunek: Schemat architektury Diffusion Model

Wyniki eksperymentów


Model	Training Time	Convergence	Total time
Autoencoder	~4 sec	Epoch 169	
Conditional VAE	~13.5 sec	Epoch 104	
Convolutional VAE	~5.5 sec	Epoch 291	
GAN	~23 sec	Epoch 30	
VQ-VAE	~5 sec	Epoch 34	
Diffusion Model	~18 sec	Epoch 50	
	per epoch*		

Early stopping


- Modele monitorowane pod kątem wczesnego zatrzymania na podstawie metryki rekonstrukcji.
- Najlepsze wyniki osiągnięto przy minimalizacji straty rekonstrukcji.
- Trening przerywany, gdy nie obserwowano poprawy przez 10 epok.

* Czas treningu mierzony na urządzeniu z Apple M4 Pro (20 rdzeni GPU)


Krzywe uczenia




Rysunek: Krzywa uczenia
Autoencodera




Rysunek: Krzywa uczenia
Conditional VAE




Rysunek: Krzywa uczenia
Convolutional VAE



Rysunek: Krzywa uczenia
VQ-VAE



Rysunek: Krzywa uczenia
Diffusion Model




Rysunek: Krzywa uczenia
GAN

Przykłady generowanych cyfr



Rysunek: Autoencoder






Rysunek: Convolutional VAE




Przykłady generowanych cyfr - cz. 2

Generated MNIST Digits (Latent Dim: 32)

Digit 0



Digit 1



Digit 2



Przykłady generowanych cyfr - cz. 3




Rysunek: Autoencoder



Rysunek: Conditional VAE




Rysunek: Convolutional VAE



Rysunek: VQ-VAE



Rysunek: Diffusion Model



Rysunek: GAN

Interpolacja w przestrzeni latentnej



Interpolacja w VAE:

- Płynne przejścia między cyframi: $0 \rightarrow 1 \rightarrow 2$
- Przestrzeń latentna ma sens semantyczny

Interpolacja w Conditional VAE:

- Interpolacja wewnątrz klasy: różne style tej samej cyfry
- Interpolacja między klasami: morfing $3 \rightarrow 8$

Wnioski - podstawowe modele

- **Autoencoder:**

- Najszybszy trening
- Najprostsza implementacja
- Ograniczona jakość generowanych próbek
- BCE loss jako metryka rekonstrukcji

- **VAE:**

- Lepsza jakość generowanych próbek
- Możliwość interpolacji w przestrzeni latentnej
- Stabilny trening
- Balans między rekonstrukcją a KL divergence

- **GAN:**

- Najlepsza jakość wizualna
- Trudny trening
- Problem z mode collapse
- Wymaga balansu między generatorem a dyskryminatorem

Wnioski - zaawansowane modele

Conditional VAE:

- Kontrolowane generowanie cyfr
- Interpolacja między cyframi
- Lepsza jakość niż standardowy VAE
- Wymaga etykiet podczas treningu

VQ-VAE:

- Dyskretna przestrzeń latentna
- Wizualizacja codebooka
- Dobre kompresja z zachowaniem jakości
- Możliwość interpolacji

Diffusion Model:

- Progresywne generowanie
- Wysoka jakość próbek
- Długi czas generowania
- Stabilny proces treningu

Najważniejsze obserwacje

- VAE i GAN osiągnęły najlepsze wyniki w generowaniu cyfr
- Conditional VAE oferuje najlepszy balans jakości i kontroli
- VQ-VAE zapewnia dobre kompresję z zachowaniem jakości
- Diffusion Model rozczarował - prawdopodobne błędy implementacyjne

Ranking modeli

- 1 **Conditional VAE:** solidny wybór dla większości aplikacji.
- 2 **Diffusion:** Najlepsza jakość, bardzo długi czas nauki i generowania.
- 3 **GAN:** Dobra jakość, trudny trening.
- 4 **Convolutional VAE:** Lepsza jakość dla obrazów, wolniejszy trening.
- 5 **VQ-VAE:** Dobra kompresja, problemy z jakością generowanych próbek.
- 6 **Basic AE:** Najszybszy trening, ograniczona jakość.

Dziękujemy za uwagę!