

Generowanie cyfr pisanych odręcznie na bazie sieci neuronowej o architekturze autoencodera

Analiza porównawcza różnych architektur oraz wyników

Jakub Barylak, Michał Jagoda, Piotr Marcol

Politechnika Śląska

11 czerwca 2025

Plan prezentacji

- 1 Wprowadzenie
- 2 Przegląd zaimplementowanych modeli i ich architektur
- 3 Wyniki eksperymentów
- 4 Wizualizacje i przykłady
- 5 Wnioski

Cel prezentacji

Przedstawienie wyników i porównanie różnych modeli generatywnych na zbiorze danych MNIST.

- Analiza architektur Autoencoderów, VAE, GAN i Diffusion Model.
- Porównanie jakości generowanych próbek.

Zaimplementowane modele


Podstawowe modele

- **Autoencoder:** Klasyczny model do rekonstrukcji danych.
- **Conditional VAE:** Wariacyjny autoencoder z warstwą warunkującą, umożliwiający generowanie danych na podstawie etykiet.
- **Convolutional VAE:** Wariacyjny autoencoder z warstwami konwolucyjnymi, lepiej przystosowany do obrazów.

Zaawansowane modele

- **Vector Quantized VAE (VQ-VAE):** Model łączący VAE z dyskretną przestrzenią latentną.
- **Generative Adversarial Network (GAN):** Model oparty na rywalizujących sieciach neuronowych.
- **Diffusion Model:** Model generatywny oparty na procesie redukcji szumu.

Architektura Autoencodera



Rysunek: Schemat architektury Autoencodera

Architektura Conditional VAE



Rysunek: Schemat architektury Conditional VAE

Architektura Convolutional VAE




Rysunek: Schemat architektury VAE

Architektura GAN




Rysunek: Schemat architektury GAN

Architektura VQ-VAE



Rysunek: Schemat architektury VQ-VAE

Architektura Diffusion Model



Rysunek: Schemat architektury Diffusion Model

Liczba parametrów modeli

Model	Liczba parametrów	Rozmiar (MB)
GAN Generator	1,948,545	7.43
GAN Discriminator	6,851,777	26.14
VQ-VAE	202,273	0.77
Basic AE	490,992	1.87
Conditional VAE	40,626,529	154.98
Convolutional VAE	880,545	3.36
Diffusion Model	840,961	3.21

Rysunek: Porównanie liczby parametrów i rozmiaru modeli

Obserwacje

- Conditional VAE ma największą liczbę parametrów (40.6M)
- VQ-VAE jest najbardziej kompaktowy (202K parametrów)
- GAN Discriminator jest znacznie większy niż Generator
- Diffusion Model i Convolutional VAE mają podobną złożoność

Wyniki eksperymentów


Model	Czas treningu	Epoka zbieżności	Całkowity czas
Autoencoder	~4 sek	Epoka 169	11m 16s
Conditional VAE	~13.5 sek	Epoka 104	23m 24s
Convolutional VAE	~5.5 sek	Epoka 291	26m 40s
GAN	~23 sek	Epoka 30	11m 30s
VQ-VAE	~5 sek	Epoka 34	2m 50s
Diffusion Model	~18 sek	Epoka 49	14m 42s
	per epoka*		

Early stopping


- Modele monitorowane pod kątem wczesnego zatrzymania na podstawie metryki rekonstrukcji.
- Najlepsze wyniki osiągnięto przy minimalizacji straty rekonstrukcji.
- Trening przerywany, gdy nie obserwowano poprawy przez 10 epok.

* Czas treningu mierzony na urządzeniu z Apple M4 Pro (20 rdzeni GPU)


Krzywe uczenia




Rysunek: Krzywa uczenia
Autoencodera




Rysunek: Krzywa uczenia
Conditional VAE




Rysunek: Krzywa uczenia
Convolutional VAE



Rysunek: Krzywa uczenia
VQ-VAE




Rysunek: Krzywa uczenia
Diffusion Model



Rysunek: Krzywa uczenia
GAN

Przykłady generowanych cyfr

Generated MNIST Samples (Hidden Dim: 32)




Rysunek: Autoencoder

Generated MNIST Samples (Latent Dim: 32)




Rysunek: Convolutional VAE

Przykłady generowanych cyfr - cz. 2




Rysunek: Conditional VAE


Przykłady generowanych cyfr - cz. 3



Rysunek: VQ-VAE




Rysunek: GAN



Rysunek: Diffusion Model

Interpolacja w przestrzeni latentnej



Rysunek: Przedstawienie interpolacji w przestrzeni latentnej

Interpolacja w VAE:

- Płynne przejścia między cyframi: $0 \rightarrow 1 \rightarrow 2$
- Przestrzeń latentna ma sens semantyczny

Wnioski - podstawowe modele

- **Autoencoder:**

- Najszybszy trening
- Najprostsza implementacja
- Ograniczona jakość generowanych próbek
- BCE loss jako metryka rekonstrukcji

- **Convolutional VAE:**

- Lepsza jakość generowanych próbek
- Możliwość interpolacji w przestrzeni latentnej
- Stabilny trening
- Balans między rekonstrukcją a KL divergence

- **GAN:**

- Najlepsza jakość wizualna
- Trudny trening
- Problem z mode collapse
- Wymaga balansu między generatorem a dyskryminatorem

Wnioski - zaawansowane modele

Conditional VAE:

- Kontrolowane generowanie cyfr
- Interpolacja między cyframi
- Lepsza jakość niż standardowy VAE
- Wymaga etykiet podczas treningu

VQ-VAE:

- Dyskretna przestrzeń latentna
- Wizualizacja codebooka
- Dobre kompresja z zachowaniem jakości
- Możliwość interpolacji

Diffusion Model:

- Progresywne generowanie
- Wysoka jakość próbek
- Czyste, wyraźne cyfry
- Długi czas generowania
- Stabilny proces treningu

Najważniejsze obserwacje

- Conditional VAE i Diffusion Model osiągnęły najlepsze wyniki jakościowe.
- Conditional VAE oferuje najlepszy balans jakości, szybkości i kontroli.
- Diffusion Model daje świetną jakość kosztem czasu generowania.
- GAN pozostaje dobrym wyborem mimo trudności w treningu.
- VQ-VAE zaskoczył szybkością konwergencji.

Ranking modeli

- ➊ **Conditional VAE:** Najlepsza kontrola, doskonała jakość, łatwy w użyciu.
- ➋ **Diffusion:** Bardzo wysoka jakość, ale wolniejszy proces.
- ➌ **GAN:** Dobra jakość wizualna, trudniejszy trening.
- ➍ **Convolutional VAE:** Solidna jakość, dobry dla obrazów.
- ➎ **VQ-VAE:** Najszybszy trening, unikalna estetyka.
- ➏ **Basic AE:** Słaba jakość.

Rekomendacje

- Dla większości zastosowań: Conditional VAE.
- Gdy jakość jest priorytetem: Diffusion Model.

Dziękujemy za uwagę!